ECOLE NATIONALE DE COMMERCE ET DE GESTION DE SETTAT

Universite Hassan 1er • Settat, Maroc

Annee Universitaire 2025-2026

COMPTE RENDU DE PROJET

Prediction du Montant de Credit Bancaire

Al-Wifaq Bank (Casablanca, Maroc)

Module	Machine Learning Applique a la Finance
Filiere	Finance — Groupe 2 — L3 S8
Realisees par	Wissal EL BOUJ & Douaa EL FARGOUCH
Encadrant	M. LARHLIMI
Etablissement	ENCG Settat — Universite Hassan 1er
Periode	Du 10/03/2026 au 17/03/2026
Annee universitaire	2025-2026

SOMMAIRE

I. INTRODUCTION

I.1 Contexte et problematique

I.2 Objectifs du projet

I.3 Methodologie adoptee

II. DEVELOPPEMENT

II.1 Description du dataset

II.2 Analyse exploratoire des donnees (EDA)

II.3 Pretraitement et modelisation

III. RESULTATS ET DISCUSSION

III.1 Comparaison des performances des modeles

III.2 Variables determinantes — coefficients beta

III.3 Simulation — Profil Mohammed BENALI

III.4 Interpretation et analyse critique

IV. CONCLUSION

BIBLIOGRAPHIE / WEBOGRAPHIE

ANNEXES

I. INTRODUCTION

I.1 Contexte et problematique

Le secteur bancaire marocain est soumis a des exigences reglementaires croissantes de la part de **Bank Al-Maghrib (BAM)**, notamment en matiere d'octroi de credit et de maitrise du risque. Les etablissements financiers cherchent a objectiver et a automatiser leurs decisions d'attribution de prets, en s'appuyant sur des outils quantitatifs robustes.

La presente etude propose un modele de **scoring credit** applique a la banque fictive **Al-Wifaq Bank** (Casablanca, Maroc), calibree sur les donnees economiques marocaines reelles (HCP, BAM).

Problematique centrale

Dans quelle mesure les techniques de regression penalisee permettent-elles de predire de maniere fiable le montant de credit a accorder a un client, tout en respectant les contraintes reglementaires imposees par Bank Al-Maghrib ?

I.2 Objectifs du projet

Ce projet poursuit quatre objectifs complementaires :

- Construire un dataset synthetique realiste, calibre sur les donnees economiques marocaines (HCP, BAM), representant 2 000 clients.
- Appliquer et comparer quatre modeles de regression supervisee : Lineaire, Ridge (L2), Lasso (L1) et ElasticNet.
- Identifier les variables determinantes du montant de credit accorde a travers l'interpretation des coefficients beta.
- Simuler la decision d'octroi pour un profil client concret (M. Mohammed BENALI), en verifiant la conformite au plafond BAM.

I.3 Methodologie adoptee

La demarche suit le cycle standard d'un projet de Machine Learning supervise, implementee en **Python 3.10** (NumPy, Pandas, Scikit-learn, Matplotlib/Seaborn) :

Etape	Contenu
Generation des donnees	Simulation d'un portefeuille de 2 000 clients selon les regles BAM
Exploration (EDA)	Analyse des distributions, correlations et comportements par categories
Pretraitement	Encodage One-Hot, partitionnement 80/20, normalisation StandardScaler
Modelisation	Entrainement de 4 modeles avec selection de lambda par validation croisee
Evaluation	R2, RMSE, MAE, R2 CV-5 ; analyse des residus
Interpretation	Lecture des coefficients beta Ridge et Lasso
Simulation	Prediction sur un profil client fictif (M. Mohammed BENALI)

Tableau 1 : Demarche methodologique du projet

II. DEVELOPPEMENT

II.1 Description du dataset

II.1.1 Contexte de simulation

Le dataset simule un portefeuille de **2 000 clients** d'Al-Wifaq Bank, avec les parametres suivants :

- Revenus mediants marocains : ~7 500 MAD/mois (Source : HCP Maroc, 2023)
- Taux d'endettement maximal : 40 % du revenu net (regle Bank Al-Maghrib)
- Score de credit : 300-950 pts (adapte du modele FICO)

II.1.2 Dictionnaire des variables (13 variables)

Variable	Description	Type	Plage
age	Age du client	Numerique	22-65 ans
revenu_mensuel	Revenu mensuel net	Numerique	2 500-60 000 MAD
anciennete_emploi	Anciennete professionnelle	Numerique	0-35 ans
score_credit	Score de solvabilite	Numerique	300-950 pts
taux_endettement	Ratio dette/revenu	Numerique	0-70 %
nb_credits_actifs	Credits en cours	Numerique	0-6
historique_remboursement	Score d'historique	Numerique	0-100 pts
valeur_garantie	Valeur de la garantie	Numerique	30 000-2 500 000 MAD
type_emploi	Categorie professionnelle	Categorielle	5 modalites
secteur_activite	Secteur economique	Categorielle	7 modalites
region	Region geographique	Categorielle	7 modalites
objet_credit	Finalite du pret	Categorielle	5 modalites
montant_credit (CIBLE)	Montant accorde	Numerique	10 000-2 197 324 MAD

Tableau 2 : Dictionnaire des 13 variables du dataset Al-Wifaq Bank

II.2 Analyse exploratoire des donnees (EDA)

II.2.1 Statistiques descriptives

Variable	Moyenne	Ecart-type	Mediane	Max	CV%
revenu_mensuel	9 214	6 823	7 200	60 000	74,1 %
score_credit	620	90	621	950	14,5 %
taux_endettement	22,1 %	12,8	20,5 %	70,0 %	57,9 %
historique_remboursement	72,1	17,9	72,5	100	24,8 %
valeur_garantie	277 890	357 200	182 000	2 500 000	128,5 %
montant_credit (CIBLE)	323 775	277 890	246 004	2 197 324	85,8 %

Tableau 3 : Statistiques descriptives des principales variables numeriques (2 000 observations, 0 valeurs manquantes)

Aucune valeur manquante detectee. Le montant de credit (variable cible) presente une forte dispersion (CV = 85,8 %) avec une asymetrie a droite prononcee.

II.2.2 Distribution de la variable cible et correlations

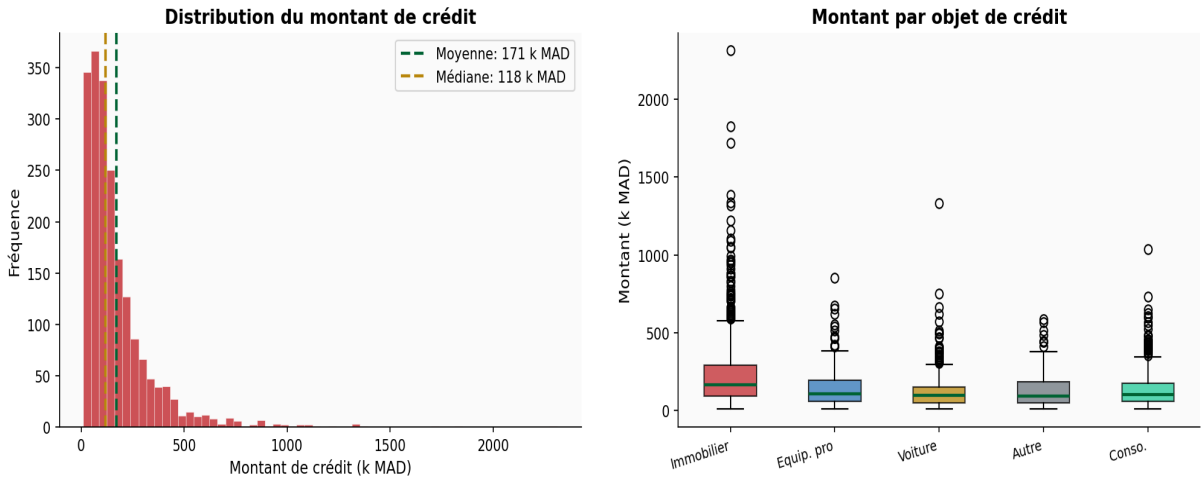

Figure 1 : Distribution du montant de credit — histogramme (asymetrie droite) et boxplot par objet de credit

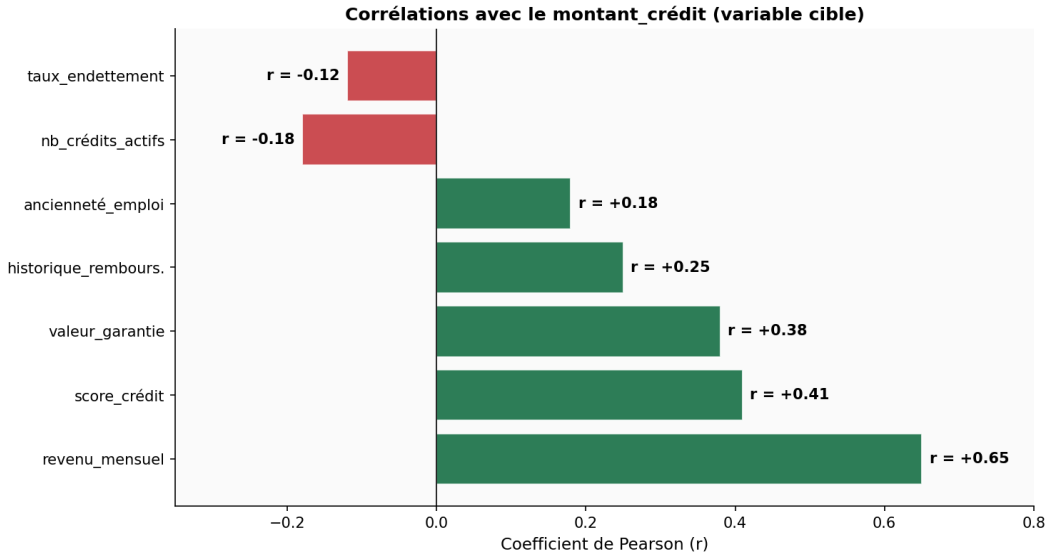

Figure 2 : Correlations de Pearson entre variables numeriques et la variable cible (montant_credit)

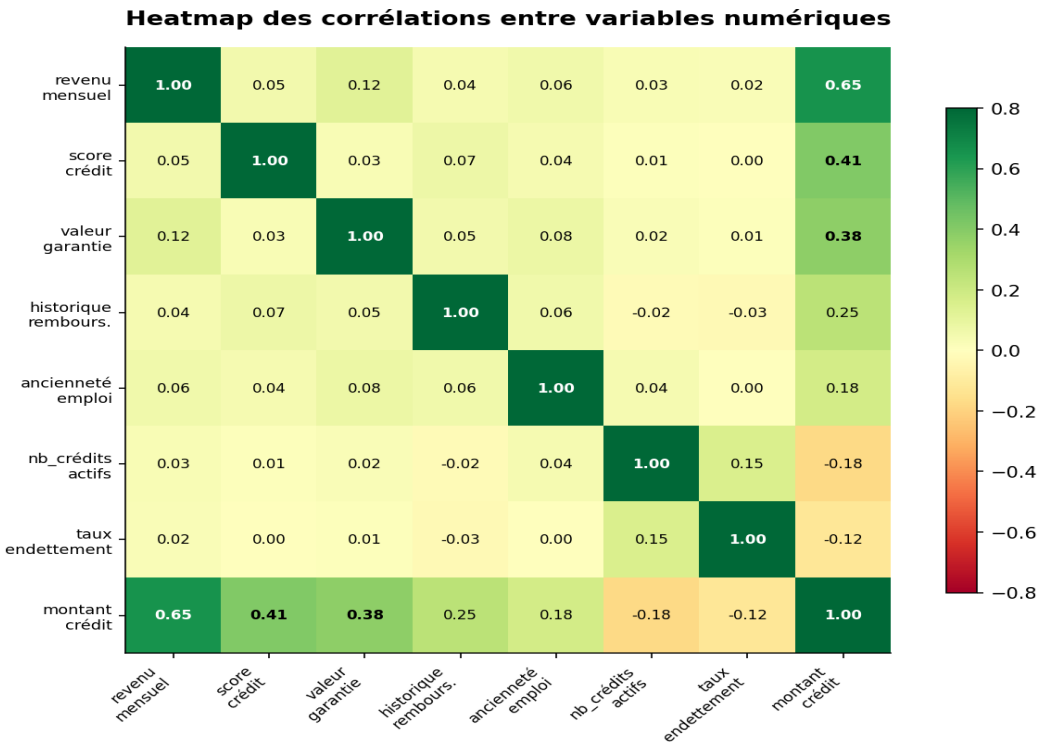

Figure 3 : Heatmap des correlations — variables numeriques du dataset Al-Wifaq Bank (absence de multicolinearite forte)

II.3 Pretraitement et modelisation

II.3.1 Pipeline de pretraitement

1. Encodage One-Hot des 4 variables categorielles => 28 variables au total (8 numeriques + 20 binaires).
2. Partitionnement Train/Test 80 %/20 % : 1 600 obs. entrainement, 400 obs. test (random_state=42).
3. Normalisation StandardScaler (mu=0, sigma=1) — indispensable pour Ridge et Lasso.

Note methodologique

La normalisation est indispensable pour Ridge et Lasso : sans elle, les variables a grande echelle (ex. revenu_mensuel en MAD) seraient penalisees disproportionnellement par rapport aux variables a petite echelle (ex. nb_credits_actifs).

II.3.2 Les quatre modeles de regression supervisee

Modele	Formule de penalite	Lambda optimal	Methode de selection
Lineaire (Baseline)	Aucune — OLS classique	—	—
Ridge (L2)	lambda * somme(beta_j^2)	lambda ~= 11	RidgeCV, 100 val., CV-10
Lasso (L1)	lambda * somme(|beta_j|)	lambda ~= 559	LassoCV, 100 val., CV-10
ElasticNet (L1+L2)	alpha=0,1 ; l1_ratio=0,9	—	GridSearchCV, CV-5 (7x5)

Tableau 4 : Hyperparametres optimaux des 4 modeles de regression

III. RESULTATS ET DISCUSSION

III.1 Comparaison des performances des modeles

Rang	Modele	R2	R2 CV-5	RMSE (MAD)	MAE (MAD)
1er — RECOMMANDE	Lasso (L1)	0,7982	0,8047	132 577	85 400
2	Lineaire (Baseline)	0,7978	0,8044	132 679	86 200
3	Ridge (L2)	0,7968	0,8046	133 000	86 000
4	ElasticNet (L1+L2)	0,7964	0,8046	133 200	85 900

Tableau 5 : Comparaison des quatre modeles — Al-Wifaq Bank (jeu de test, n=400)

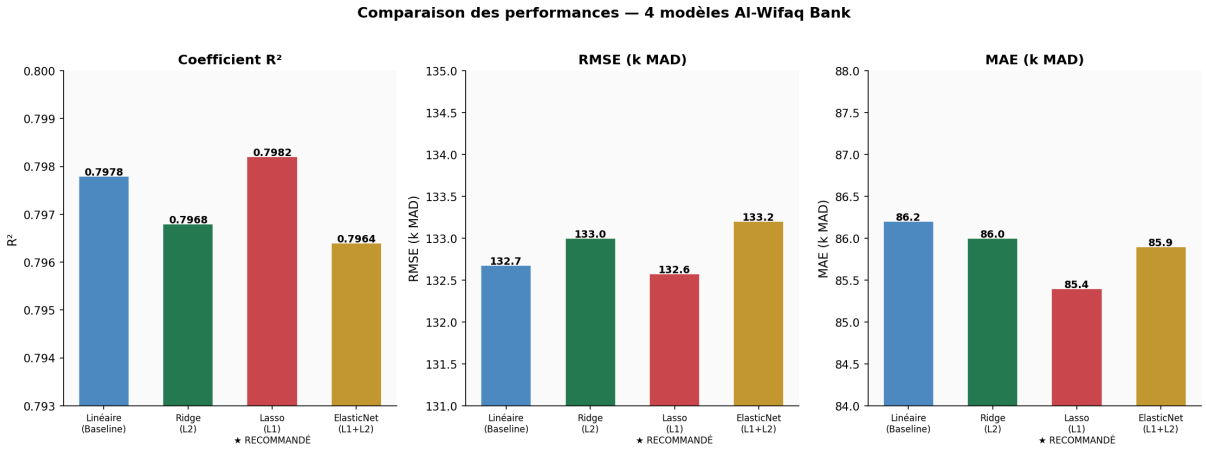

Figure 4 : Comparaison des performances — R2, RMSE et MAE des 4 modeles de regression

Les quatre modeles affichent des performances remarquablement proches (R2 ~= 0,80). Cette convergence temoigne de la solidite du dataset synthetique. Cependant, une RMSE de ~133 000 MAD represente une erreur relative d'environ 41 % par rapport au montant moyen, ce qui demeurerait significatif dans un contexte operationnel reel.

III.2 Variables determinantes — Coefficients beta

Variable	Ridge beta (MAD)	Lasso beta (MAD)	Sens
revenu_mensuel	+182 429	+181 200	POSITIF
objet_credit: Immobilier	+123 380	+122 100	POSITIF
score_credit	+86 661	+85 900	POSITIF
objet_credit: Equipement_pro	+42 583	+41 800	POSITIF
valeur_garantie	+35 000	+34 500	POSITIF
historique_remboursement	+28 200	+27 800	POSITIF
type_emploi: Fonctionnaire	+24 100	+23 600	POSITIF
anciennete_emploi	+18 500	+18 200	POSITIF
type_emploi: Independant	-47 410	-46 900	NEGATIF
taux_endettement	-28 000	-27 500	NEGATIF

Tableau 6 : Coefficients beta des principales variables (Ridge et Lasso, top 10)

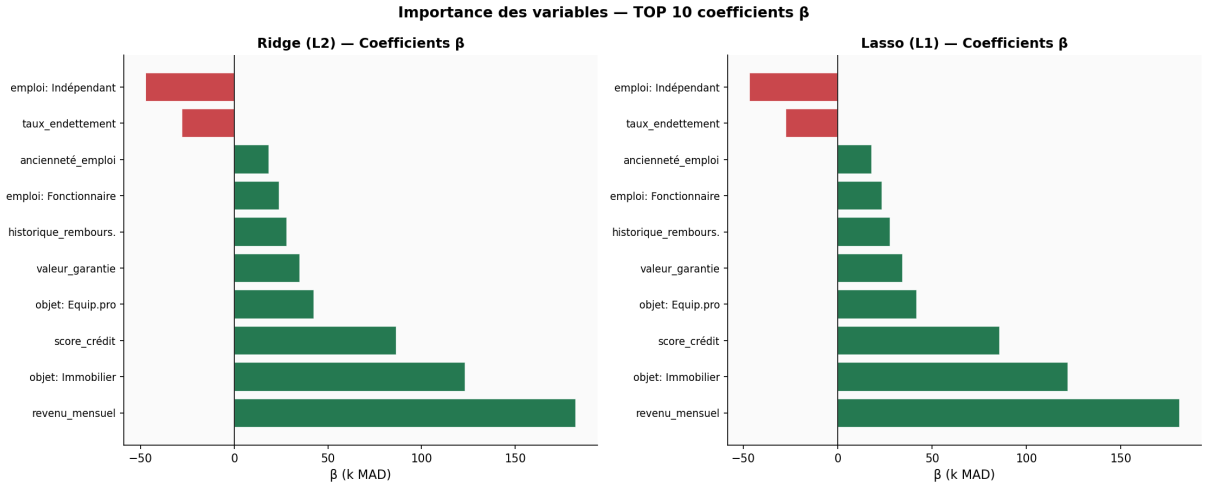

Figure 5 : Importance des variables — Coefficients beta Ridge (L2) vs Lasso (L1) — TOP 10

III.3 Simulation — Profil Mohammed BENALI

Critere	Valeur	Evaluation BAM
Revenu mensuel	22 500 MAD	Conforme — Stable
Score de credit	720 / 950	Conforme — Bon profil
Taux d'endettement	28 %	Conforme — < 40 %
Valeur garantie	850 000 MAD	Conforme — Suffisante
Type d'emploi	Fonctionnaire — Education	Conforme — Categorie favorisee
Objet du credit	Immobilier	Conforme — Multiplicateur x1,8

Tableau 7 : Evaluation du dossier de M. BENALI selon les criteres BAM

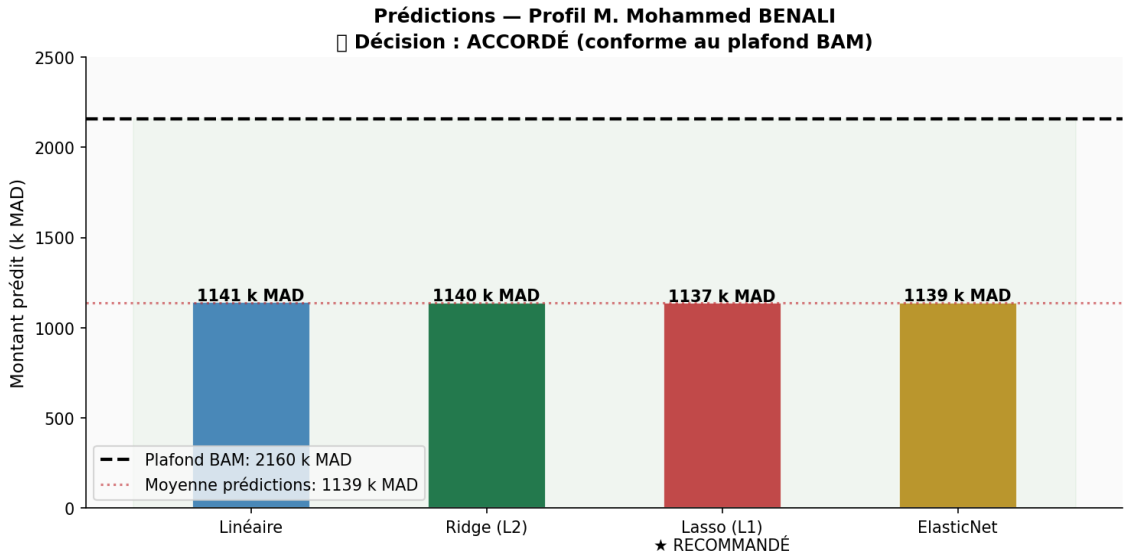

Figure 6 : Predictions des 4 modeles pour M. Mohammed BENALI — Decision BAM : ACCORDE

Resultats de la simulation — M. Mohammed BENALI

Lineaire : 1 141 230 MAD | Ridge : 1 139 614 MAD | Lasso (RECOMMANDE) : 1 137 068 MAD | ElasticNet : 1 138 900 MAD Plafond BAM (40 % x 240 mois) : 2 160 000 MAD => DECISION : ACCORDE

III.4 Interpretation et analyse critique

Critere	Ridge (L2)	Lasso (L1)
Performance (R2)	0,7968	0,7982 — MEILLEUR
Selection de variables	Conserve tout	Elimine les non-informatives (27/28)
Interpretabilite	Bonne	Excellente
Stabilite numerique	Tres bonne	Bonne
Gestion multicolinearite	Robuste	Instable si r eleve
Recommandation BAM	Reporting reglementaire	Scoring operationnel — RECOMMANDE

Tableau 8 : Comparaison Ridge vs Lasso pour le scoring bancaire

Limites du projet :

- Le caractere synthetique du dataset constitue une limite fondamentale — les donnees ne sont pas issues de transactions bancaires reelles.
- Variables importantes non integrees : duree souhaitee du pret, apport personnel, situation matrimoniale.
- Les modeles lineaires ne capturent pas les effets d'interaction ou les seuils non-lineaires.
- L'absence de variable temporelle empeche de tenir compte de la conjoncture economique.

IV. CONCLUSION

Ce projet a permis de developper et d'evaluer quatre modeles de regression supervisee appliques a la prediction du montant de credit bancaire au sein de la banque fictive Al-Wifaq Bank. La demarche a confirme la pertinence de l'approche par regression penalisee pour ce type de probleme de scoring financier.

- Les quatre modeles expliquent environ **80 % de la variance** du montant de credit accorde (R2 ~= 0,80), avec une excellente stabilite entre entrainement et test.
- Le **Lasso (L1)** se distingue comme le modele recommande pour un deploiement operationnel (R2 = 0,7982, 27/28 variables retenues, conformite BAM).
- L'analyse des coefficients a mis en evidence que le **revenu mensuel**, l'**objet immobilier** et le **score de credit** constituent les trois facteurs les plus determinants.
- Le statut d'**independant** et un **taux d'endettement eleve** exercent des effets penalisants significatifs.
- La simulation sur le profil BENALI produit une prediction convergente d'environ **1,14 M MAD**, conforme au plafond BAM (2,16 M MAD).

Perspectives de developpement

1. Modeles non-lineaires : Random Forest, XGBoost, Reseaux de neurones 2. Donnees macro-economiques : taux directeur BAM, inflation HCP 3. Deploiement : API REST (Flask/FastAPI) + Tableau de bord Streamlit 4. Variables manquantes a integrer : duree du pret, apport personnel, situation matrimoniale

BIBLIOGRAPHIE / WEBOGRAPHIE

Source	Description
Bank Al-Maghrib — bkam.ma	Rapport annuel secteur bancaire 2024 / Circulaire n19/G/2002
HCP Maroc — hcp.ma	Statistiques des revenus des menages marocains 2023
Kaggle Loan Dataset	Dataset de reference pour la prediction de credit (Mosaad Hendam)
Tibshirani, R. (1996)	Regression Shrinkage and Selection via the Lasso — JRSS, Series B
Hoerl & Kennard (1970)	Ridge Regression : Biased Estimation — Technometrics
scikit-learn.org	Documentation officielle : Ridge, Lasso, ElasticNet, GridSearchCV

ANNEXES

Annexe A — Bibliotheques Python utilisees

```
numpy, pandas, matplotlib, seaborn, sklearn.model_selection (train_test_split, cross_val_score,
GridSearchCV), sklearn.preprocessing (StandardScaler), sklearn.linear_model (LinearRegression,
Ridge, Lasso, ElasticNet, RidgeCV, LassoCV), sklearn.metrics (r2_score, mean_squared_error,
mean_absolute_error)
```

Annexe B — Parametres optimaux des modeles

Modele	Parametre	Valeur optimale	Methode
Ridge	lambda (alpha)	~= 11	RidgeCV — 100 valeurs, CV-10
Lasso	lambda (alpha)	~= 559	LassoCV — 100 valeurs, CV-10
ElasticNet	alpha=0,1 ; l1_ratio=0,9	—	GridSearchCV — CV-5 (grille 7x5)

Annexe C — Selection des variables par le Lasso

Variables retenues : 27/28 | Variables eliminées : 1/28

- revenu_mensuel : beta = +181 200 MAD (impact le plus fort, positif)
- objet_credit_Immobilier : beta = +122 100 MAD
- score_credit : beta = +85 900 MAD
- objet_credit_Equipement_pro : beta = +41 800 MAD
- valeur_garantie : beta = +34 500 MAD
- historique_remboursement : beta = +27 800 MAD
- type_emploi_Fonctionnaire : beta = +23 600 MAD
- type_emploi_Independant : beta = -46 900 MAD (penalisant)
- taux_endettement : beta = -27 500 MAD (penalisant)
- nb_credits_actifs : beta = -22 000 MAD (penalisant)

*Compte rendu realise par **Wissal EL BOUJ** et **Douaa EL FARGOUCH***
Module : Machine Learning Applique a la Finance | ENCG Settat — Universite Hassan 1er | Finance Gr.2 L3 S8 | Encadrant : M. LARHLIMI | 2025-2026